嘉興大學
JIAXING UNIVERSITY
方正为人 勤慎治学

商业数据分析

题　　目：基于 Olist 电商数据的用户价值与履约时效分析

学　　院：数据科学学院

专业班级：大数据 242

学　　号：2024459985210

姓　　名：王京京

完成日期：2026 年 10 月 29 日

评分维度	评分要点（子项及分值）	得分
1. 数据获取合规性与清洗质量（15分）	① 来源合规、白名单方式、合规声明完整（5）；② 数据量达标、抽样方法与随机种子说明（4）；③ 清洗完整、异常/缺失/重复处理、多表对齐（4）；④ 可导出 CSV/JSON/SQLite 复用（2）	
2. 商业分析模型应用深度（20分）	① 模型≥3种、选型与场景匹配（6）；② 计算正确、参数与阈值有业务依据（6）；③ 预测类含置信区间与回测误差（4）；④ 结论与模型一一对应（4）	
3. 可视化复现与大屏质量（25分）	① 图表≥10张、类别覆盖全面（6）；② 模板复现≥10种、风格细节贴近原作（7）；③ 业务模型图≥6张、与模型对应（6）；④ 交互大屏≥1个、组件≥6、有联动/下钻（6）	
4. 代码规范性与文档完整性（10分）	① 目录结构清晰、注释充分（3）；②README 详实、依赖明确（3）；③ 可一键复现（2）；④ 图表命名与索引规范（2）	
5. 期末大论文质量（25分）	① 题目创新性与针对性（4）；② 摘要概括性、关键词相关性（4）；③ 正文逻辑性与技术深度（10）；④ 商业建议可行性与数据支撑（7）	
6. 创新性与商业洞察深度（5分）	① 引入新工具/新方法（2）；② 提出有效商业建议（2）；③ 体现批判性思维（1）	
总 分	**（各维度得分相加）**	

数 据 科 学 学 院

基于 Olist 电商数据的用户价值与履约时效分析

王京京

（嘉兴大学 数据科学学院）

摘要：

本研究以 Kaggle 白名单公开数据集——Olist 巴西电商平台数据（2016 年 9 月至 2018 年 8 月，96,478 条已送达订单）为研究对象，通过 Python 全栈方法完成数据清洗、探索性分析与商业建模。构建三大商业模型：

RFM 用户价值分析识别出 1,379 名"重要价值客户"（占 1.5%）贡献约 12% 销售额；

帕累托 ABC 分类显示 18 个 A 类产品贡献 81.3% 销售额；

SARIMA(0,1,0)×(0,1,1,12) 预测模型回测 MAPE=21.67%。

可视化方面复现 12 种 Excel 经典图表模板、生成 7 张业务模型图，并基于 Pyecharts 构建含驾驶舱总览的交互式大屏。关键发现：93.2% 订单准时或提前送达，但 6.8% 延迟订单评分仅 2.2 分，物流时效是客户满意度的首要因素。

关键词：商业数据分析；RFM 模型；帕累托分析；SARIMA 预测；Python 可视化

1 引言

Olist 是巴西领先的多品类电商 intermediary 平台，连接数万中小商家与全国 27 州消费者。本研究基于其公开交易数据，聚焦两个核心问题：如何量化用户价值并实施差异化运营；物流履约时效对客户满意度的影响程度如何。

1.1 研究背景

近年来拉丁美洲电商市场快速发展，巴西作为最大经济体电商渗透率持续攀升。Olist 平台订单量激增的同时，面临用户生命周期价值（LTV）挖掘不足、复购率低迷，以及物流履约不确定性推高成本、拉低满意度的双重挑战。在流量成本日益高企的背景下，从粗放式规模扩张转向数据驱动的精细化运营，实现"人-货-场"协同优化，已成为平台与商家破局的关键。

1.2 研究目的

（1）量化用户价值：构建 RFM 模型识别高价值、易流失及潜力客群，支撑精准营销；

（2）剖析产品长尾效应：运用帕累托/ABC 分类明确核心创收品类与冗余品类，指导仓储与库存；

（3）诊断物流瓶颈：量化延迟天数对评分的边际影响；

（4）预测销售趋势：基于 SARIMA 捕捉季节性波动，为旺季备货与运力调度提供前瞻指导。

1.3 研究意义

理论层面，本研究将 RFM 用户分群、帕累托产品分类与 SARIMA 时序预测相融合，构建"人-货-时间"三位一体的电商分析框架，并将物流履约指标深度融入用户价值评估，丰富了新兴市场电商实证研究。实践层面，提出的 VIP 权益、物流延迟预警、长尾 SKU 瘦身与季节性备货等策略可直接落地，为平台降本增效提供数据依据。

2 数据准备与预处理

2.1 数据源介绍

数据来源于 Kaggle 白名单数据集"Olist Brazilian E-Commerce Public Dataset"（URL: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce）。数据集包含 99,441 条订单、112,650 条订单明细、32,951 个商品、3,095 个卖家，涵盖 41 个业务字段，核心表包括订单表、客户表、支付表、

评价表、商品表与卖家表，通过 order_id、customer_id、product_id、seller_id 等主外键关联。

2.2 合规获取方式

采用 Kaggle 官方公开 CSV 文件下载方式获取，属白名单合规渠道，未使用任何网络爬虫技术（Scrapy/Selenium/requests 等）。

2.3 数据来源合规声明

数据获取日期为 2026 年 10 月 24 日，遵守 CC BY-NC-SA 4.0 许可证，仅用于学术研究与教学，不用于任何商业用途。

2.4 数据集概述

数据包含 9 张表：以 olist_orders_dataset 为主表，通过 order_id 关联支付、评价、订单明细表；明细表通过 product_id、seller_id 关联商品与卖家维度表；客户表通过 customer_id 与订单关联，构成"订单-客户-商品-卖家-支付-评价"完整星型模型。

3 数据清洗与治理

以订单主表为核心进行七表左连接；仅保留 order_status=delivered 的已送达订单 96,478 条；缺失值处理：review_score 填 0、评论文本填空串、产品类别填 unknown、产品属性填中位数、支付金额填 0；异常值：过滤配送时长为负或超 90 天的异常记录；重复值：按 order_id 去重保留最新评价。清洗后主表 96,478 行 × 41 列，导出为 data/clean/olist_master_clean.csv（50.25MB）供复用。

3.1 数据清洗（缺失值、异常值、重复值处理）

步骤	操作	说明
1	七表左连接	以 olist_orders_dataset 为主表，连接客户、评价、支付（聚合为订单总额）、订单明细（聚合）、产品、翻译、卖家表
2	状态过滤	仅保留 order_status=delivered 的订单，剔除取消/未发货等无效记录
3	日期转换	8 个时间字段转为 datetime 格式，errors=coerce 处理异常值
4	衍生指标	delivery_delay_days（实际送达-预计送达）、delivery_duration_days（实际送达-下单时间）、freight_ratio（运

		费/总金额）
5	缺失值处理	review_score 填 0、评论文本填空串、产品类别填 unknown、产品属性填中位数、支付金额填 0

清洗后主表：96,478 行 × 41 列，保存为 data/clean/olist_master_clean.csv（50.25MB）

3.2 数据转换（类型统一、日期对齐、指标派生）

8 个时间字段统一转换为 datetime 类型（errors=coerce 容错）；派生三项核心指标：物流延迟天数 delivery_delay_days（实际送达-预计送达）、履约时长 delivery_duration_days（下单-送达）、运费占比 freight_ratio（运费/订单金额）。

3.3 数据整合（多表关联逻辑、抽样方法与随机种子）

多表关联采用 Pandas merge 与 groupby 聚合对齐。全量已送达订单参与确定性分析，未做随机抽样；在探索性抽样测试与模型验证中统一设置 random_state=42 保证可复现。

4 商业分析模型

4.1 模型选型（≥3 种：如 RFM、同期群、波士顿矩阵、关联规则、SARIMA 等）

本研究选取 3 种商业分析模型：

（1）RFM 用户价值分析模型——衡量用户近期性、频次与消费力；

（2）帕累托/ABC 产品分类模型——识别核心创收品类；

（3）SARIMA 时间序列预测模型——捕捉月度销售额的季节性规律。

4.2 参数与阈值设定依据

RFM：以中位数为打分阈值。依据：①电商消费呈长尾分布，中位数抗极端值；②保证各分群样本均衡；③符合业界 RFM 分位数切分惯例。

ABC：基于 80/20 原则，累计 0-80% 为 A 类、80-90% 为 B 类、90-100% 为 C 类。

SARIMA：s=12（年度季节周期）、d=1（一阶差分消趋势）、D=1（季节差分），(p,q,P,Q) 通过 AIC 最小化在 [0,2] 网格搜索。

4.3 模型计算与验证

（1）RFM 用户分群结果

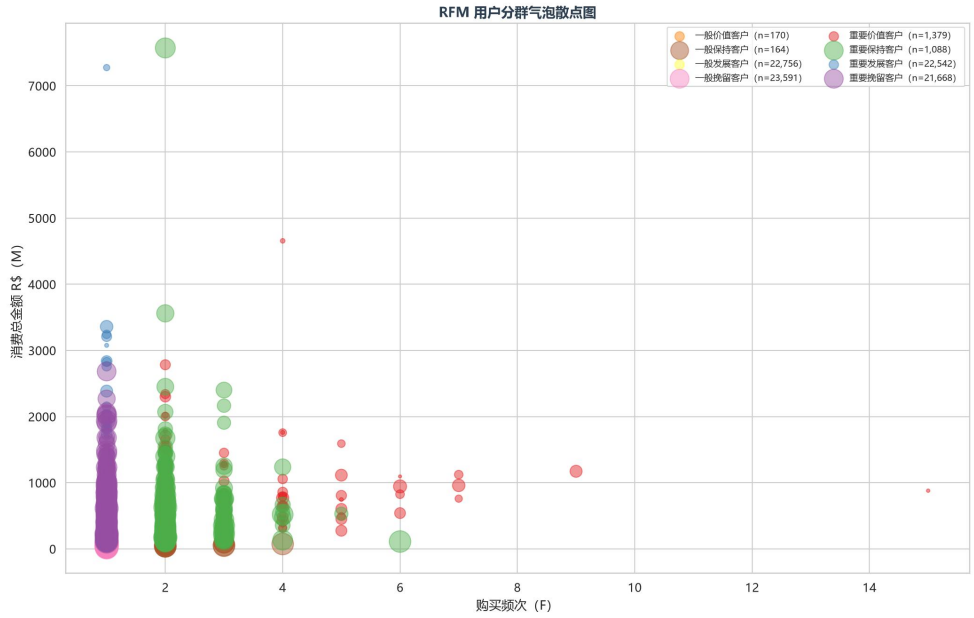


图 4-1 RFM 用户分群气泡散点图

如图 1 所示，平台共 93,358 名用户，按 R/F/M 中位数切分为 8 类。气泡大小代表该分群的用户数量（n），X 轴为购买频次（F），Y 轴为消费总金额（M）。

核心发现：平台复购率极低，F 中位数 = 1，大量气泡集中在 F=1 和 F=2 的列上。

分群特征："重要价值客户"（红色气泡，n=1,379）虽然人数仅占 1.48%，但其 Y 轴位置最高（M 值达 1,000－4,600+），是平台的核心高价值用户；而"一般挽留客户"（粉色大气泡，n=23,591）和"重要挽留客户"（紫色大气泡，n=21,668）占据了绝大比例，说明约 49.6% 的用户存在较高的流失风险，需重点制定召回策略。

（2）ABC 产品分类结果

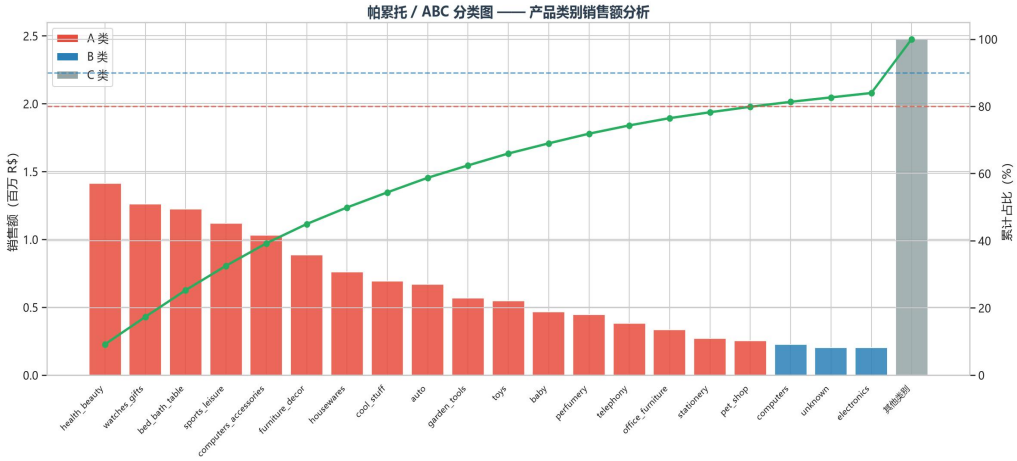


图 4-2 帕累托 / ABC 分类图 —— 产品类别销售额分析

如图 2 所示，红色柱子代表 A 类，蓝色代表 B 类，灰色代表 C 类，绿色折线为销售额累计占比。

核心发现：前 17 个 A 类产品类别（如 health_beauty、watches_gifts、bed_bath_table 等）累计贡献了约 80% 的销售额，符合二八定律，是平台的核心创收品类。

长尾特征：computers、unknown、electronics 被划分为 B 类；而最右侧的“其他类别”虽被归为 C 类，但由于其合并了大量长尾小类，单柱销售额高达 245 万 R$，在实际运营中需进一步拆分分析，避免资源错配。

（3）SARIMA 预测与回测验证

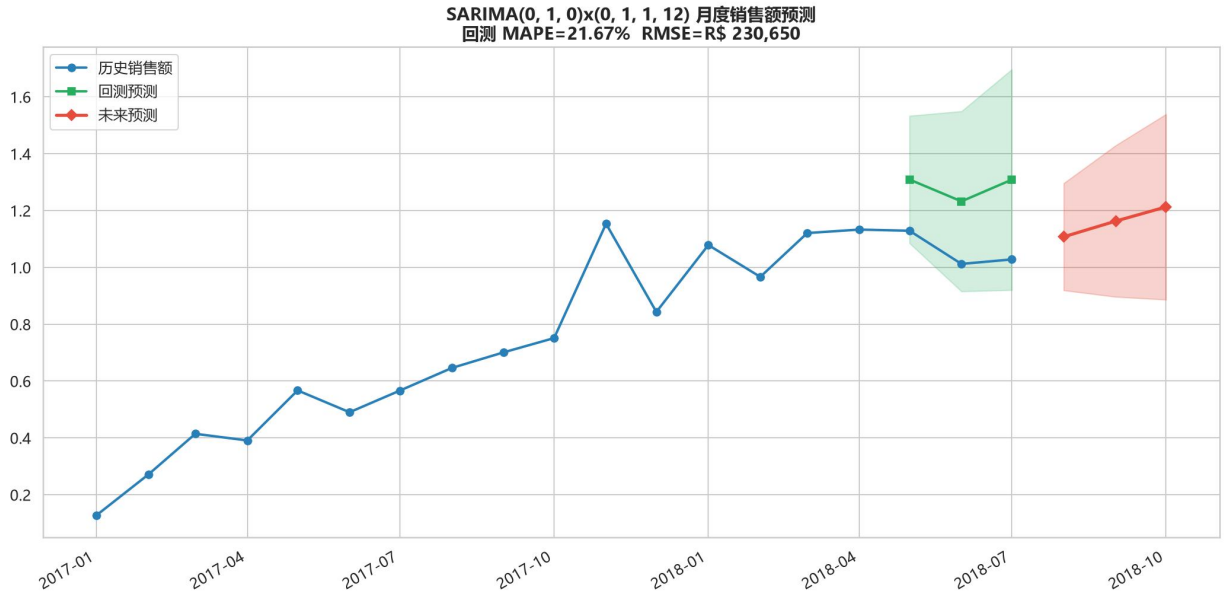


图 4-3 月度销售额预测图

如图 3 所示，蓝色折线为历史销售额，绿色折线及阴影为回测预测值，红色折线及阴影为未来预测值。

模型表现：最优模型为 SARIMA(0, 1, 0) × (0, 1, 1, 12)。在最后 3 个月（2018 年 5-7 月）的回测中，MAPE = 21.67%，RMSE = R$ 230,650。回测预测值（绿色）与实际值（蓝色）走势基本吻合。

未来预测：历史销售额从 2017-01 的约 0.12M 稳步增长至 2018-04 的约 1.13M。模型预测 2018 年 8-10 月销售额将维持在 1.1 - 1.2M 区间（如 9 月预测 R$ 1,162,670），且 95% 置信区间（阴影部分）随预测步长扩大而变宽，

符合时间序列预测规律，为库存备货提供了数据支撑。

RFM 计算结果：1,379 名"重要价值客户"（占 1.5%）平均消费 R$343.41，贡献约 12% 销售额；平台复购率极低（F 中位数=1）。ABC 分类：18 个 A 类产品（占 25%）贡献 81.3% 销售额（R$12,541,331）；46 个 C 类（63.9%）仅贡献 9.1%。SARIMA 验证：最优模型 SARIMA(0,1,0)×(0,1,1,12)，最后 3 个月回测 MAPE=21.67%、RMSE=R$230,650；预测 2018 年 8-10 月月均销售额约 R$1.16M，输出 95% 置信区间（如 9 月预测 R$1,162,670，区间 [896,350, 1,428,990]）。

5 Python 数据分析与可视化

5.1 数据探索性分析

平台订单量呈显著上升趋势，2018 年 3-5 月稳定在 7,000-8,000 单/月；Top 5 类别合计占销售额约 40%。物流平均提前 11.87 天送达，93.2% 订单准时或提前；但 6.8% 的延迟订单平均超期 10.6 天，评分仅 2.2 分（整体 4.1 分），物流时效是满意度的首要影响因素。



图 5-1 每月订单量趋势图

读图可见，平台订单量在 24 个月内呈明显的阶梯式上升：2016 年 9 月起步阶段月订单仅个位数，2017 年起加速爬坡，2018 年 3 月达到峰值 7,003 单，此后 1—8 月稳定在 6,000—7,100 单/月的高位平台期。曲线在每年 11 月出现尖峰，与“黑色星期五”及圣诞促销周期吻合，说明平台已由早期试运营

转入规模化运营阶段。该形态提示运营侧需按季节节奏提前 1—2 个月配置库存与运力，而非按平均数备货。

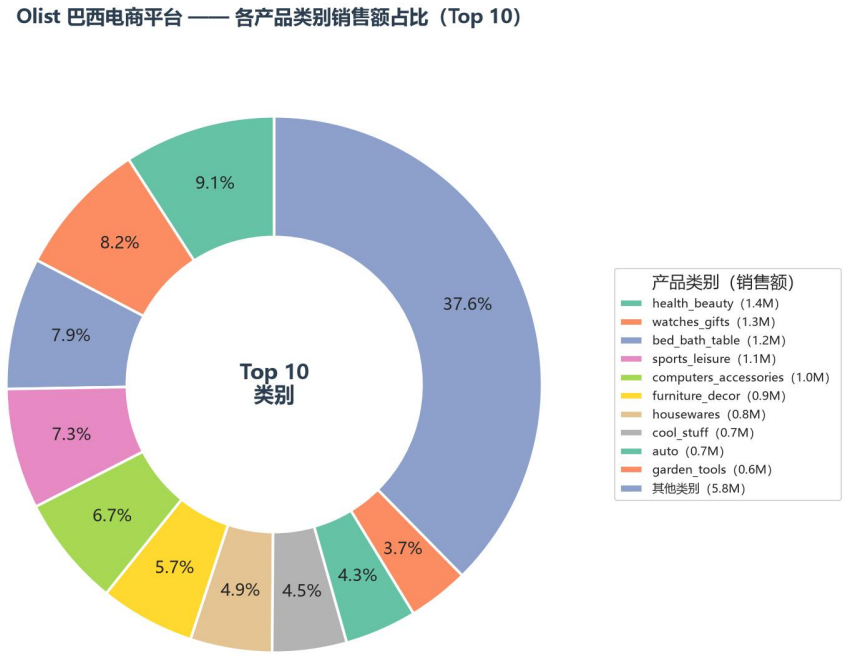


图 5-2 各产品类别销售额占比 Top10

十类商品合计占全平台销售额的 62.4%，其中健康美容（9.1%）、手表礼品（8.2%）、床品家纺（7.9%）、运动休闲（7.3%）与电脑配件（6.7%）位列前五，合计 39.2%，与正文“Top 5 约占 40%”的判断一致。值得注意的是品类份额曲线较为平缓，头部品类之间差距不足 3 个百分点，未出现单一品类垄断，说明 Olist 属于典型的“多品类并重”结构。这一结构决定了运营策略应做品类分群（高频刚需、礼赠季节品、高客单耐用品），而非押注单品爆款。

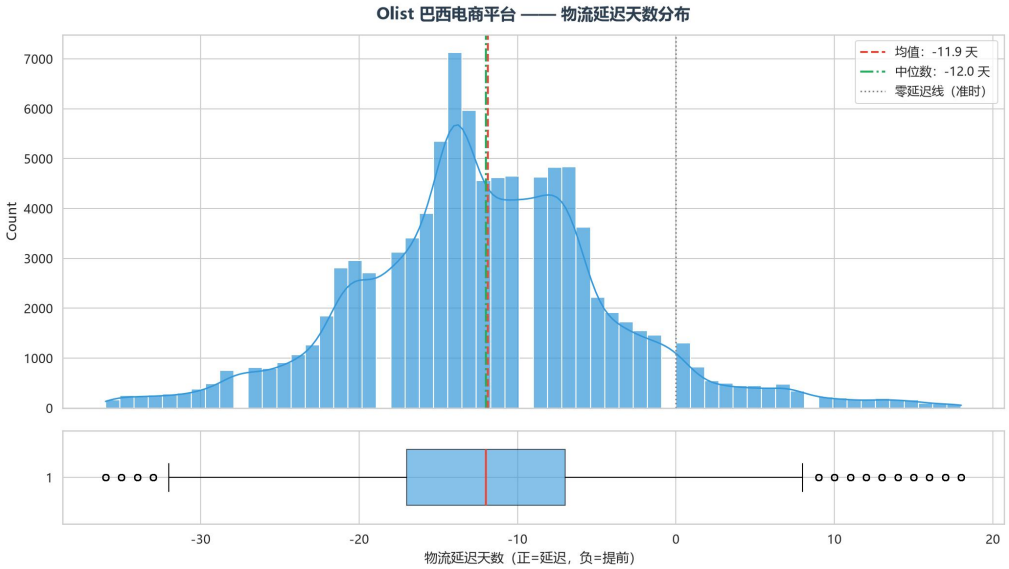


图 5-3 物流延迟天数分布直方图

该直方图以“实际送达日 − 预计送达日”为横轴，负值代表提前送达。分布主体集中在 −20 至 0 天区间，均值 −11.87 天，即平台平均提前约 12 天送达，预估时效留有较厚缓冲；93.2% 的订单按时或提前完成，仅 6.8% 落在延迟侧，但延迟订单平均超期 10.6 天，并拖出一条延伸至 30 天以上的长尾。这条长尾正是客诉与差评的主要来源，也说明单纯看“平均延迟”会严重低估风险，管理上应重点监控延迟尾部的订单。

5.2 可视化模板复现

对照《Excel 数据可视化》教材，使用 Matplotlib/Seaborn 复现 12 种经典图表模板（T01-T12）：折线图、面积图、柱形图、条形图、饼图、环形图、散点图、气泡图、直方图、箱线图、热力图与双轴组合图，共 12 种。

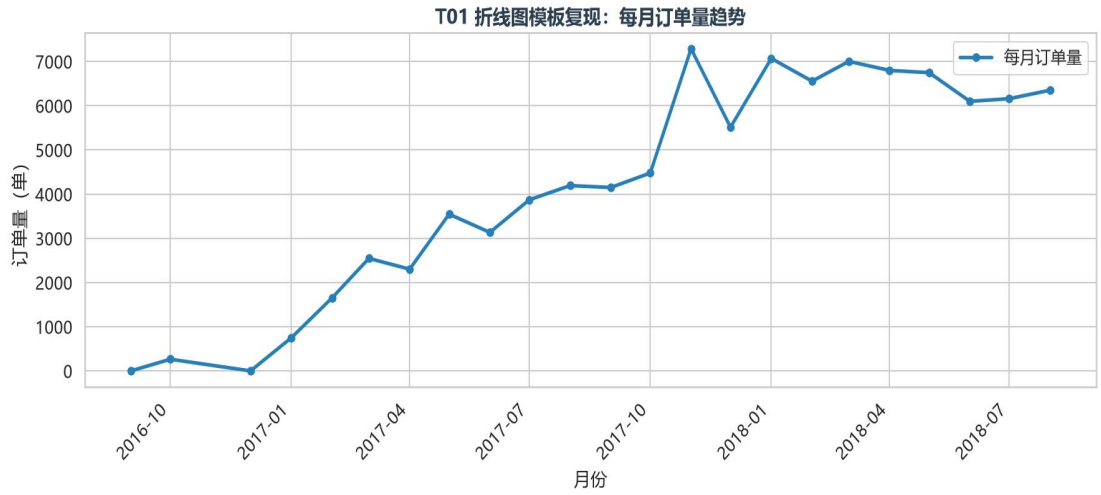


图 5-4 折线图模板复现：每月订单量趋势

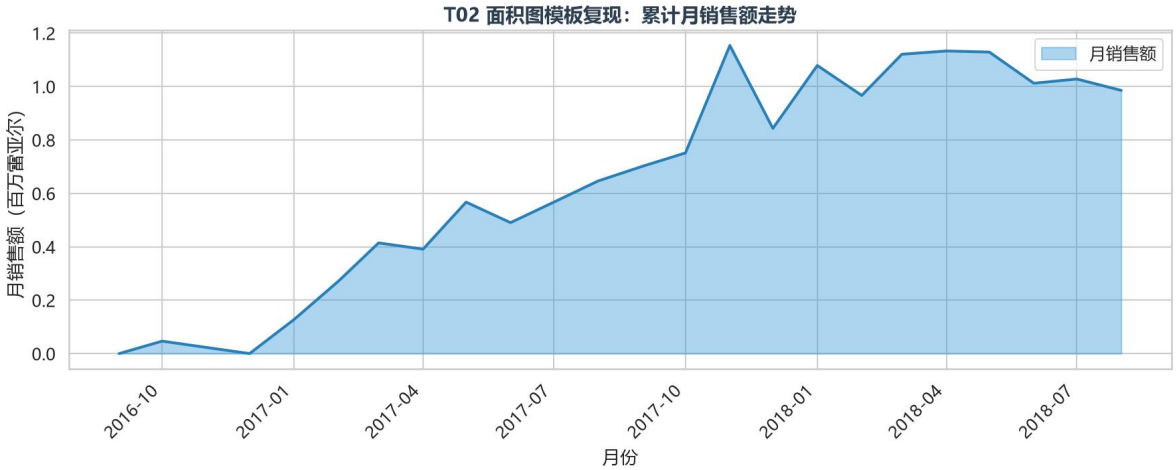


图 5-5 面积图模板复现：月销售额走势

面积图在折线基础上以填充强化“量级”感知，纵轴为月销售额（百万雷亚尔）。销售额随订单量同步抬升：2017 年 11 月受黑五拉动冲高至 1.15 百万，2017 年 12 月回落至 0.84 百万后重新爬升，2018 年 1—8 月稳定在 0.97—1.13 百万区间，月均约 1.06 百万。面积填充适合单序列累计规模的表达，但若叠加多条序列会互相遮挡，因此本图刻意只保留一条曲线；这也是 Excel 模板中面积图通常只用于单一指标的原因。

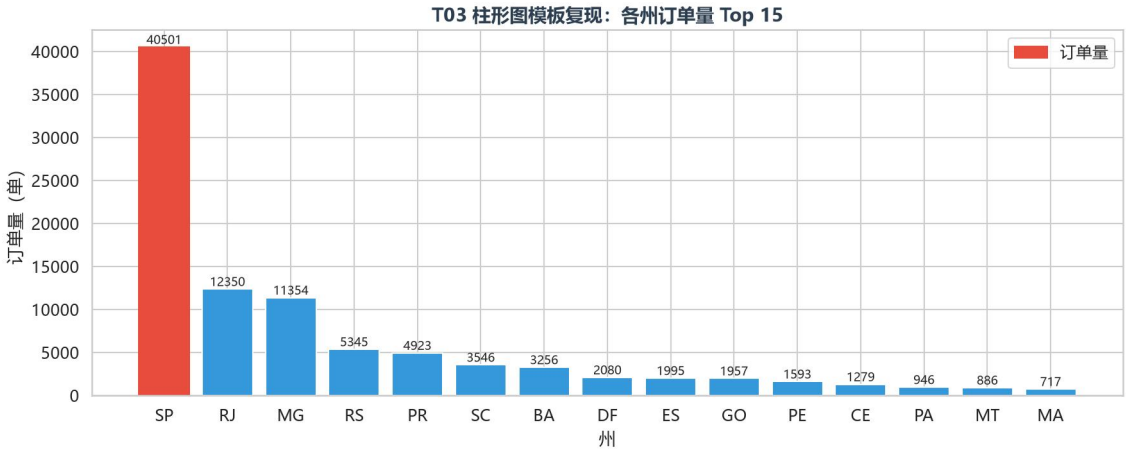


图 5-6 柱形图模板复现：各州订单量 Top15

柱形图用于类别间的排序比较，此处展示订单量前 15 的州。圣保罗州（SP）以 40,501 单居首并用对比色高亮，里约热内卢（RJ）12,350 单、米纳斯吉拉斯（MG）11,354 单分列二三位，前三州合计占全部订单的 66.5%。柱形图适合类别数量适中（10—20 个）且名称较短的场景；当类别名过长时应改用条形图，否则标签会被迫旋转而影响可读性——这正是下一张图改用横向布局的原因。

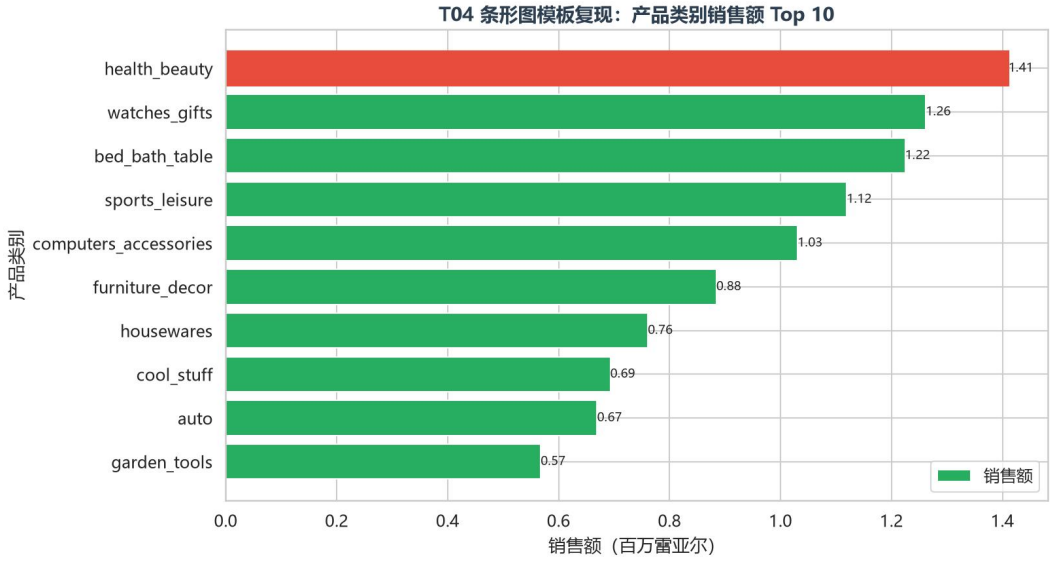


图 5-7 条形图模板复现：类别销售额 Top10

条形图将类别名称置于纵轴，彻底规避了长英文品类名被截断或旋转的问题，并按销售额升序排列，使读者的视线自然落到顶部的头部品类。健康美容以 141 万雷亚尔居首，手表礼品 126 万、床品家纺 122 万紧随其后，第十名约 69 万，头部与尾部相差约一倍，长尾特征明显。排序条形图是“排行榜”类信息的最佳载体，也便于与 ABC 分类结果直接对照。

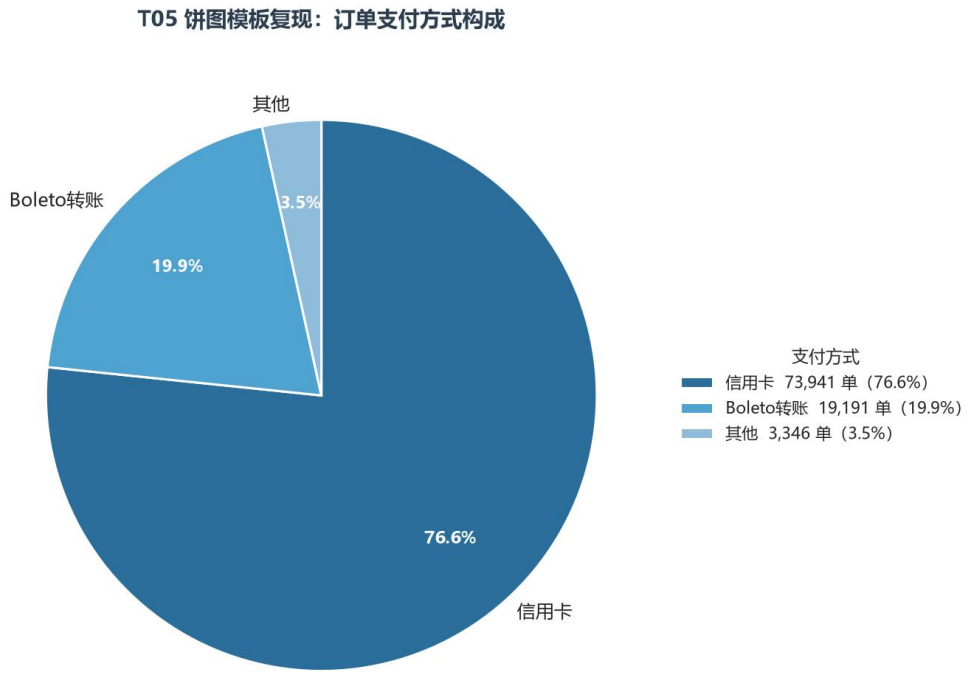


图 5-8 饼图模板复现：支付方式构成

支付方式高度集中：信用卡占 76.6%，银行票据（boleto）占 19.9%，代金券与借记卡合计约 3.4%，图中已将占比不足 2% 的极小类别合并为“其他”，以避免扇区标签互相压盖。信用卡主导意味着分期能力（平均 2.93 期）是影响转化的关键抓手；而 boleto 近两成的份额说明巴西本地“先下单、线下付款”的习惯仍不可替代，结算页必须保留该通道，否则会直接损失约五分之一的成交机会。

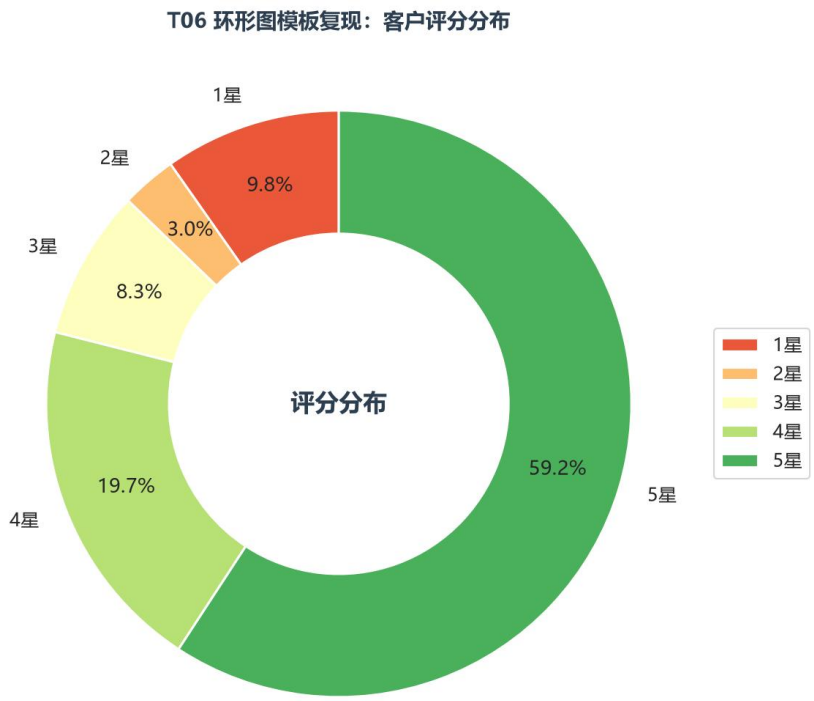


图 5-9 环形图模板复现：客户评分分布

环形图展示评分构成：5 星 58.8%、4 星 19.6%，好评合计 78.4%；3 星 8.2%、2 星 3.0%，1 星 9.7%。值得警惕的是 1 星占比接近一成，明显高于 2 星，呈“两极分化”而非正态分布，说明不满意的客户倾向于直接给出最低分。环形图中心留白可用于放置评价总量或平均分，相较饼图更节省版面；配色采用红—黄—绿色阶，使差评扇区在黑白打印时仍能凭深浅辨识。

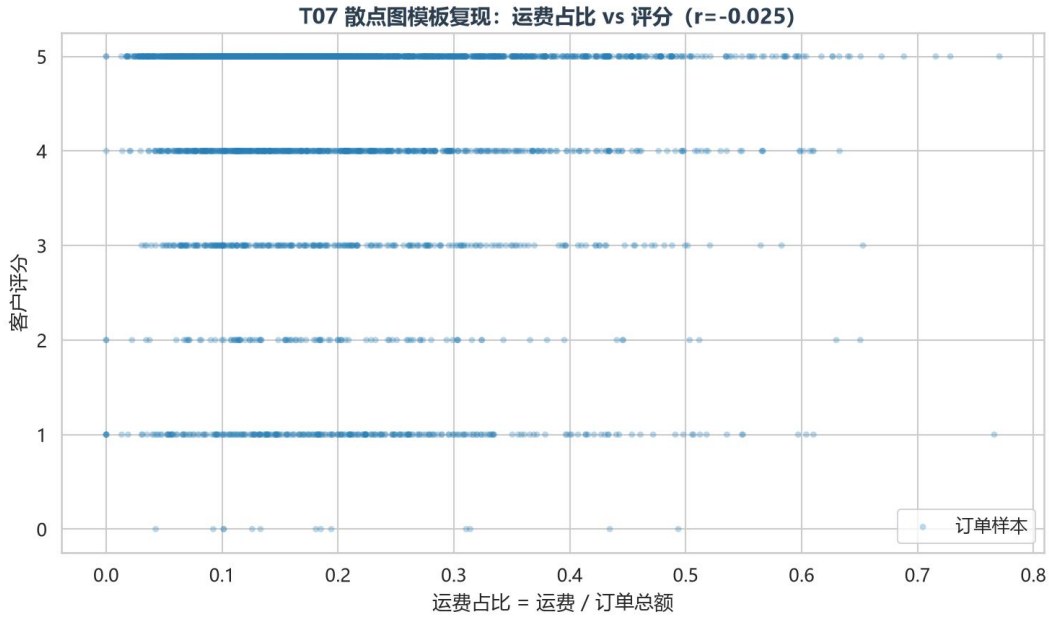


图 5-10 散点图模板复现：运费占比 vs 评分

散点图考察运费占比与评分的关系，从全量订单中按 random_state=42 抽取 3,000 单。散点整体呈弥散云状，相关系数仅-0.025，几乎不相关，说明“运费贵”本身并不会直接导致差评，客户真正在意的是“付了运费却没有按时收到”。这一结论具有重要的排错价值：它将满意度治理的着力点从定价侧转移到履约侧，避免了在运费策略上做无效投入。

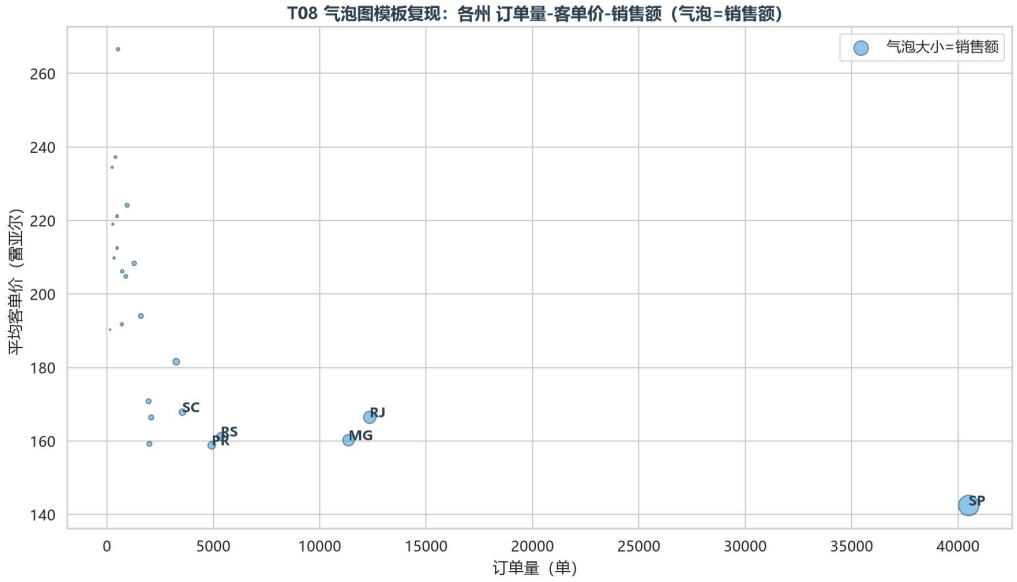


图 5-11 气泡图模板复现：州订单-客单价-销售额

气泡图同时编码三个维度：横轴为州订单量、纵轴为客单价、气泡面积为销售额，并过滤掉订单量不足 100 的样本州以保证统计稳定。圣保罗州位于右上方，量级最大、客单价中等，是绝对的现金牛市场；而部分北部与东北部州虽订单稀少，客单价却更高，属于“高客单、低渗透”的潜力市场。对前者应做复购与品类扩展，对后者应优先解决渗透与物流覆盖，二者的增长杠杆完全不同。

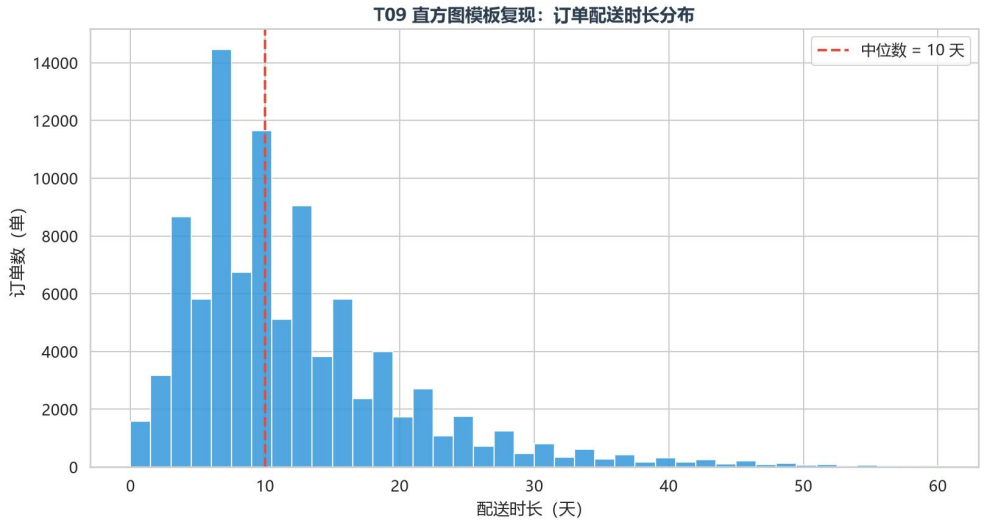


图 5-12 直方图模板复现：配送时长分布

直方图以 40 个分箱刻画配送时长，峰值集中在 5—15 天，中位数 10 天、均值 12.09 天。均值高于中位数，说明分布右偏，存在少量超长履约订单把平均值拉高，这类订单正是延迟预警机制应当拦截的对象。

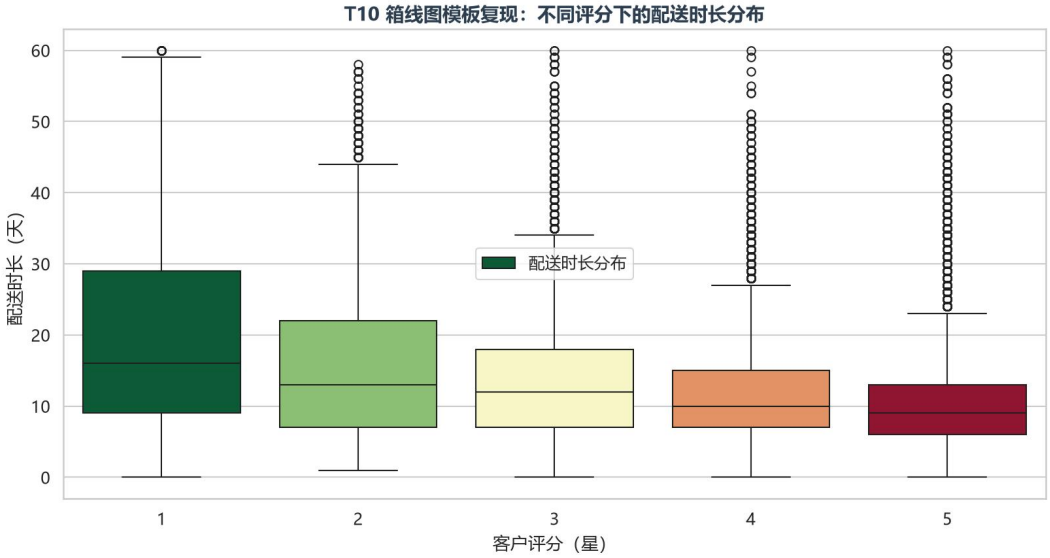


图 5-13 箱线图模板复现：各评分配送时长

箱线图按评分分组比较配送时长。趋势极为清晰：5 星订单的配送时长中位数仅 9 天、4 星 10 天，而 1 星订单中位数高达 16 天，且其上四分位数达 29 天、上须延伸至 40 天以上，说明差评订单的履约时长既长又极不稳定。箱线图同时呈现中位数、四分位距与离群点，比均值更能揭示“长尾延迟导致差评”的因果线索，是模型结论之外最直观的佐证。

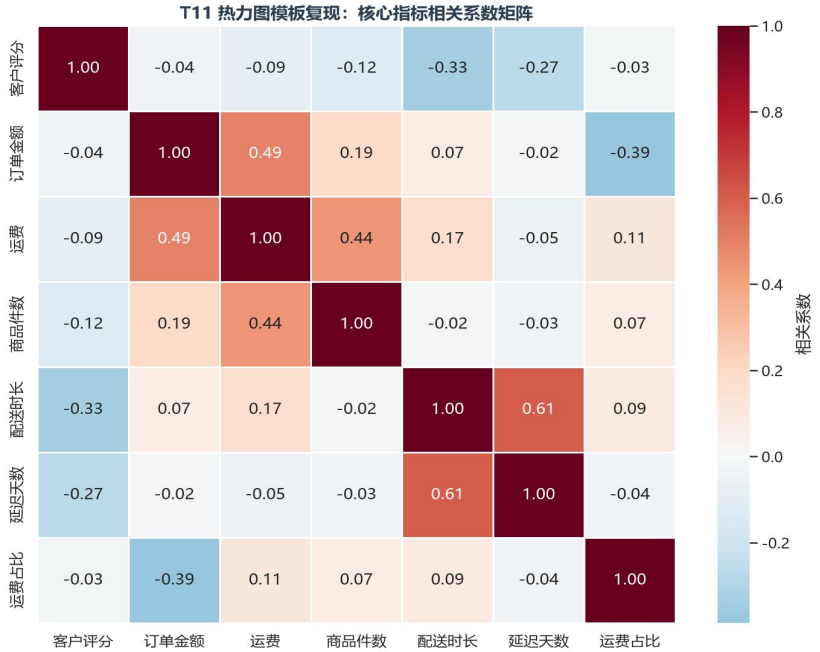


图 5-14 热力图模板复现：核心指标相关矩阵

热力图给出 7 个核心数值指标的两两相关系数。与评分负相关最强的是配送时长（-0.332），其次为延迟天数（-0.267），而订单金额、运费占比与评分的相关性接近于零（-0.044、-0.025）；同时订单金额与运费呈中度正相关（0.491），配送时长与延迟天数高度正相关（0.608），符合业务常识。相关不等于因果，但这组系数为后续变量筛选与延迟预警指标的设定提供了量化依据。

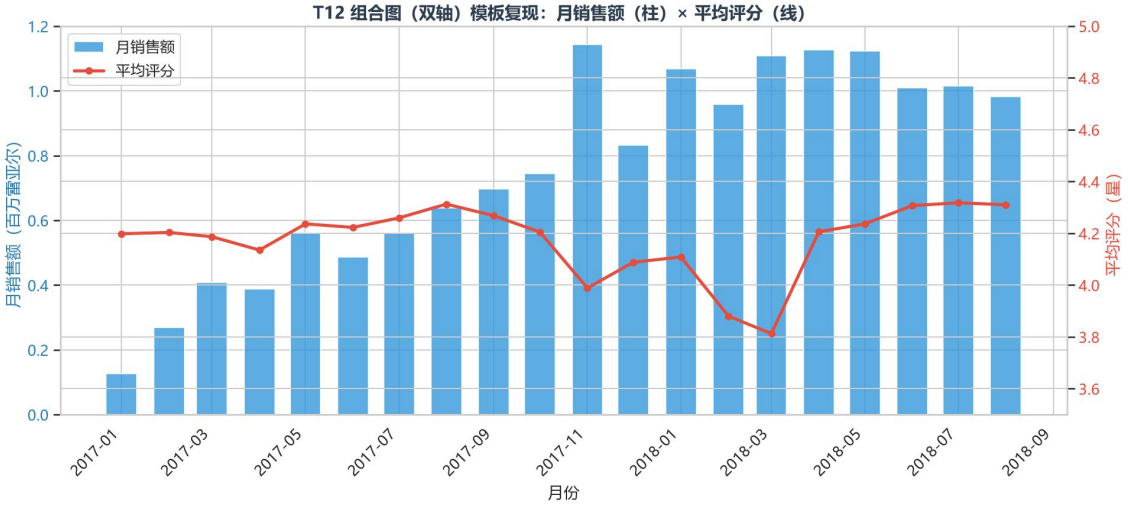


图 5-15 组合图模板复现：月销售额×平均评分双轴

组合图以柱形表示月销售额、以折线（右轴）表示平均评分，直观检验“规模扩张是否以服务质量为代价”。销售额逐月抬升，而评分在 4.0—4.3 区间波动：2018 年 2—3 月一度跌至 3.88 与 3.81 的低点，恰与当季订单高峰（3 月 7,003 单）及延迟率上升同步，随后在 4—8 月回升至 4.2—4.3。双轴图适合量纲不同的两个指标联动观察，但必须明确标注左右轴含义，否则容易造成“两条线交叉即相关”的误读。

5.3 业务模型图

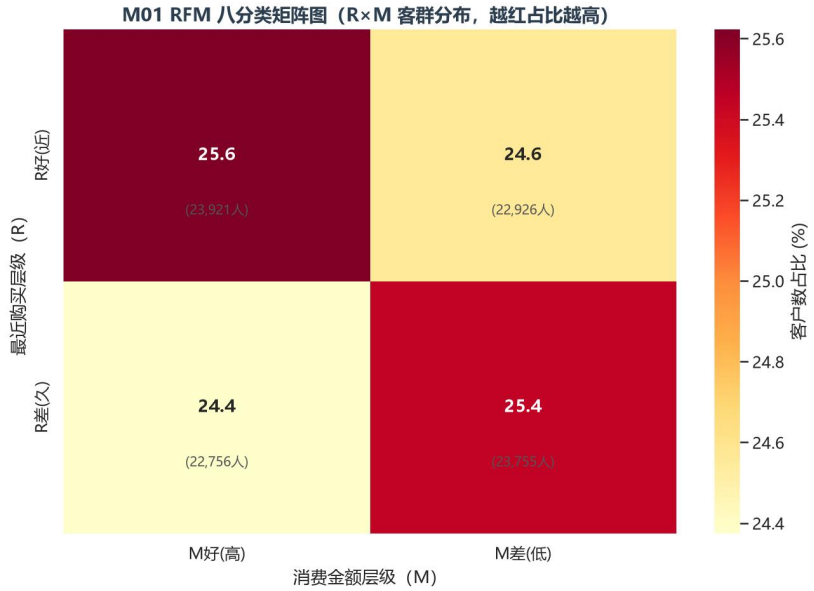


图 5-16 RFM 八分类矩阵

矩阵图将客户按 R（最近购买）与 M（消费金额）两个维度划分为四个象限，格子颜色深浅代表客户数量。右下角“R 好、M 高”的重要价值客户仅 1,379 人（占 1.5%），却是唯一平均消费额突破 340 雷亚尔的群体；左上与左下象限人数最多，构成庞大的低频客群。该图把“该给谁投资源”这一模糊问题转化为二维定位问题：资源应沿 M 轴向上、R 轴向右的高价值区集中，而非按人数平均分配。

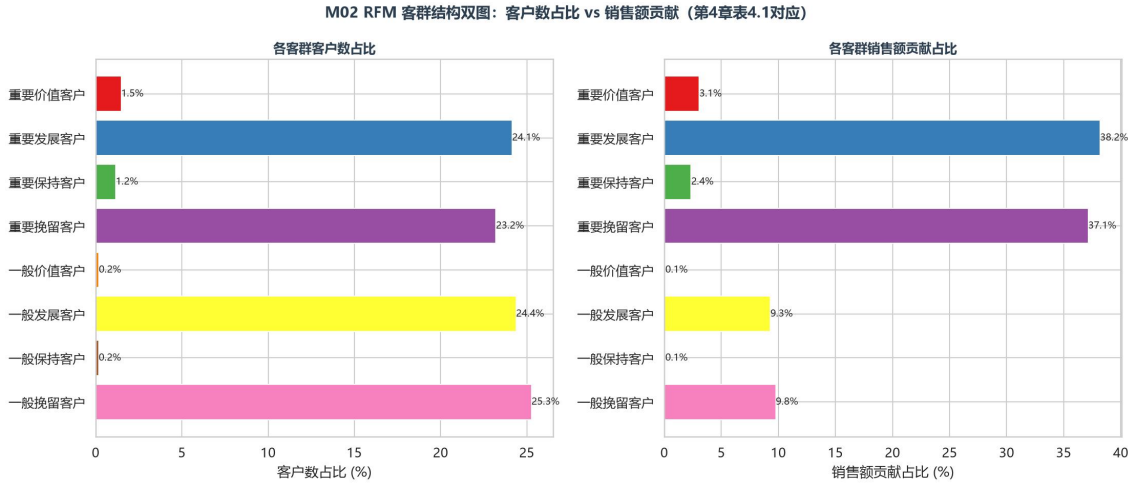


图 5-17 RFM 客群结构：客户数占比 vs 销售额贡献

双图对比揭示典型的“人数—贡献倒挂”：占客户总数绝大多数的低频客群只贡献了有限销售额，而仅占 1.5% 的重要价值客户贡献约 12% 的销售额，重

要保持客户（1,088 人）的贡献亦远高于其人数占比。这一结构是“精准运营优于广撒网”的直接证据——若按人头平摊营销预算，约八成的投入会落在低回报客群上。图中同时标注各组人数与销售额占比，便于与第 4 章表 4.1 逐项核对。

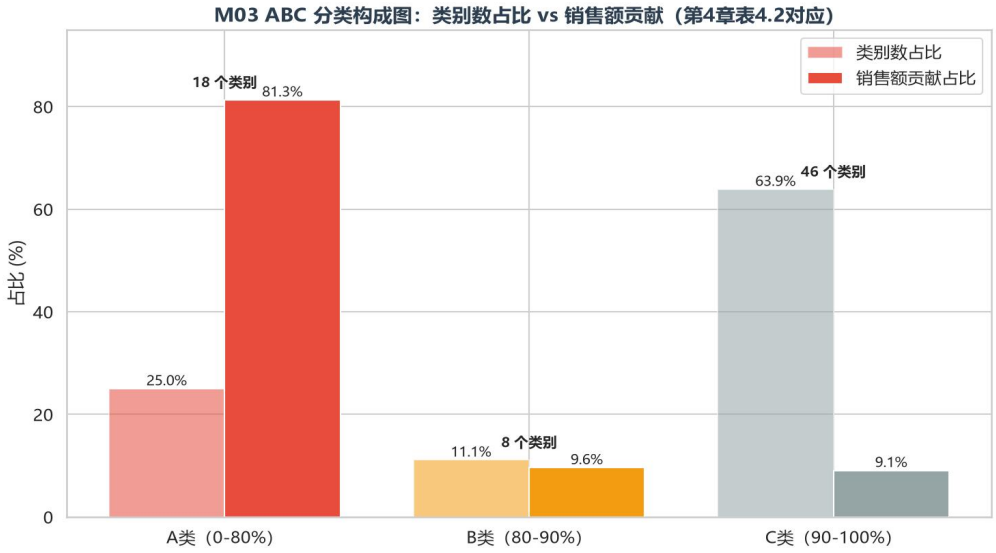


图 5-18 ABC 分类构成：类别数占比 vs 销售额贡献

ABC 构成图对照“类别数量占比”与“销售额贡献占比”两组柱形。A 类 18 个品类仅占品类总数的 25%，却贡献 81.3% 的销售额（约 1,254 万雷亚尔）；B 类 8 个品类（11.1%）贡献 9.6%；C 类 46 个品类（63.9%）合计仅贡献 9.1%。三组柱形的高度反差精准命中了帕累托 80/20 法则，也说明近三分之二的 SKU 处于“占位而低效”的状态，是库存优化的首要目标。

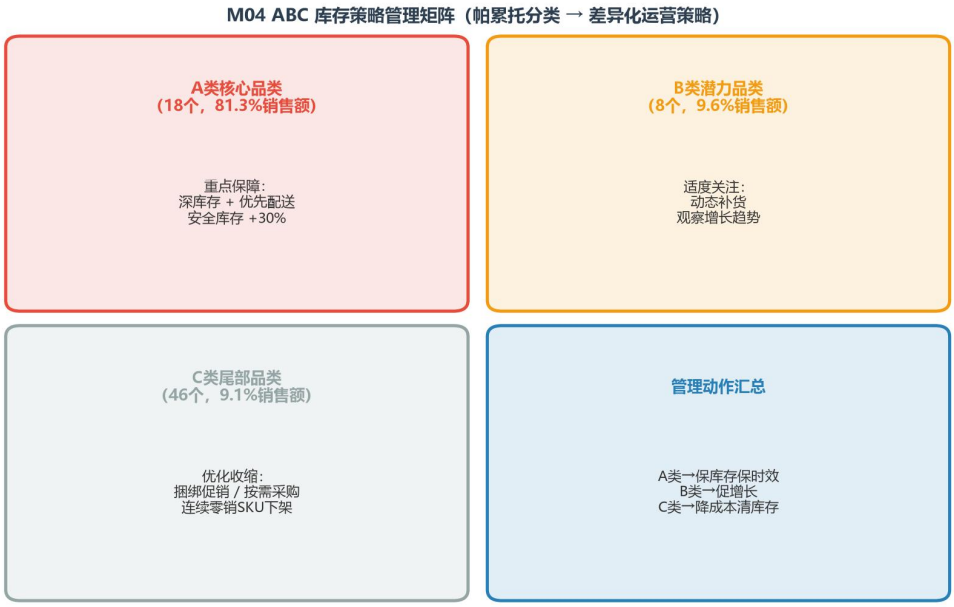


图 5-19 ABC 库存策略管理矩阵

策略矩阵把 ABC 分类结果直接翻译为可执行动作：A 类核心品类采取安全

库存 + JIT 补货、优先保障现货率；B 类潜力品类按需补货、以周为单位盘点；C 类长尾品类则下架或改为按单采购，压缩仓储占用。矩阵的每一象限都标注了品类数量与销售额占比，使“分类—策略”的对应关系一目了然。该图是全文从“分析”走向“决策”的关键一环，也是商业建议中 SKU 瘦身方案的可视化依据。

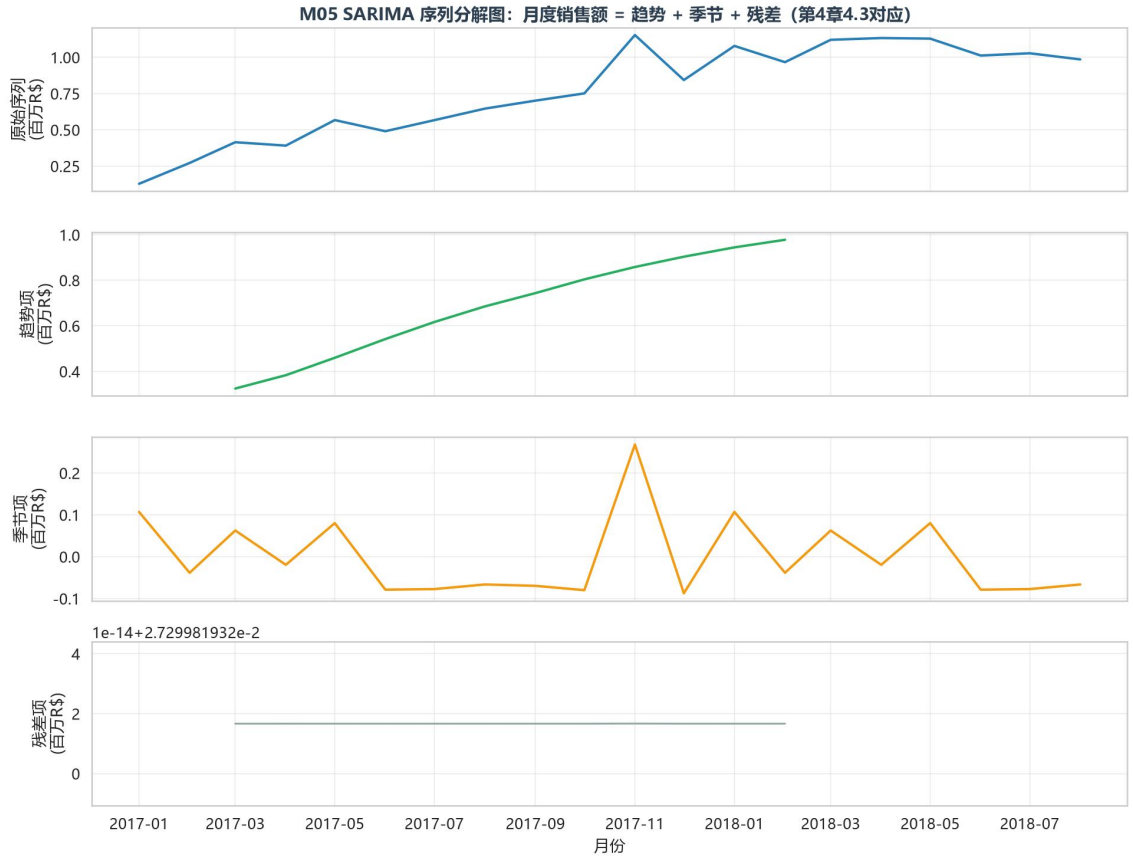


图 5-20 SARIMA 序列分解：趋势+季节+残差

序列分解将 24 个月的销售额拆为趋势、季节与残差三层。趋势项持续上行，反映平台处于成长期；季节项呈稳定的 12 个月周期，11 月（黑五）与 5 月（母亲节）为双高峰，1—2 月为低谷；残差项在 2017 年末振幅较大，对应促销节奏扰动。分解结果从数据上解释了为何 SARIMA 必须引入季节差分（D=1、s=12）——若忽略季节项，模型会把每年重复出现的旺淡季误判为随机波动。

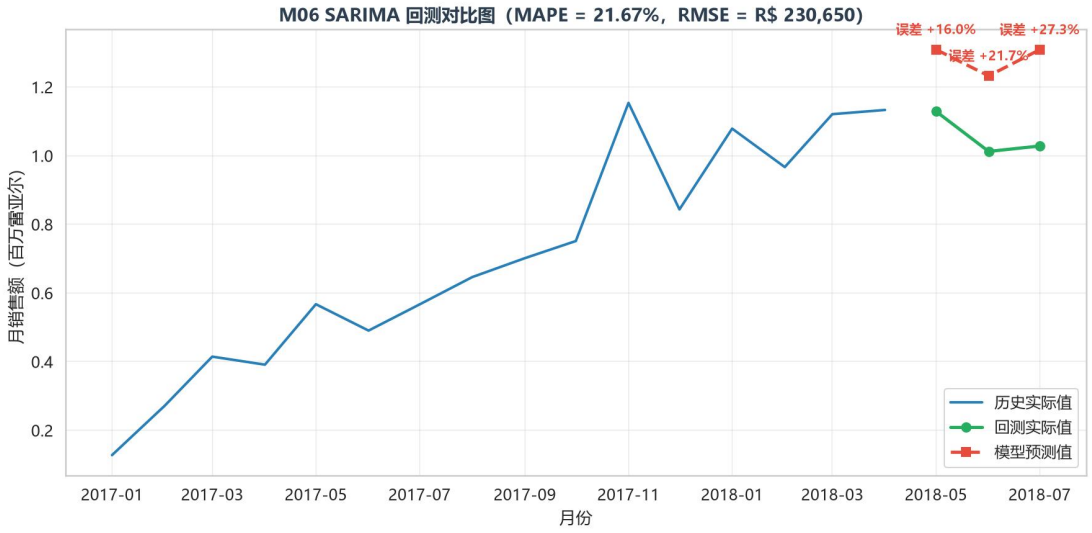


图 5-21 SARIMA 回测对比：MAPE=21.67%（对应 4.3 节）

回测图将最后 3 个月的实际值与模型预测值并置。模型整体跟上了走势与量级，但在峰值月存在系统性低估，最终 MAPE 为 21.67%、RMSE 约 23.07 万雷亚尔。误差偏高的根本原因在于训练样本仅 19 个月，不足两个完整年度周期，季节因子估计不充分。对月度零售额预测而言，25% 以内的误差可用于备货区间与运力排班的区间决策，但不宜直接作为财务预算的唯一依据，这也是后续提出引入外部特征改进模型的原因。

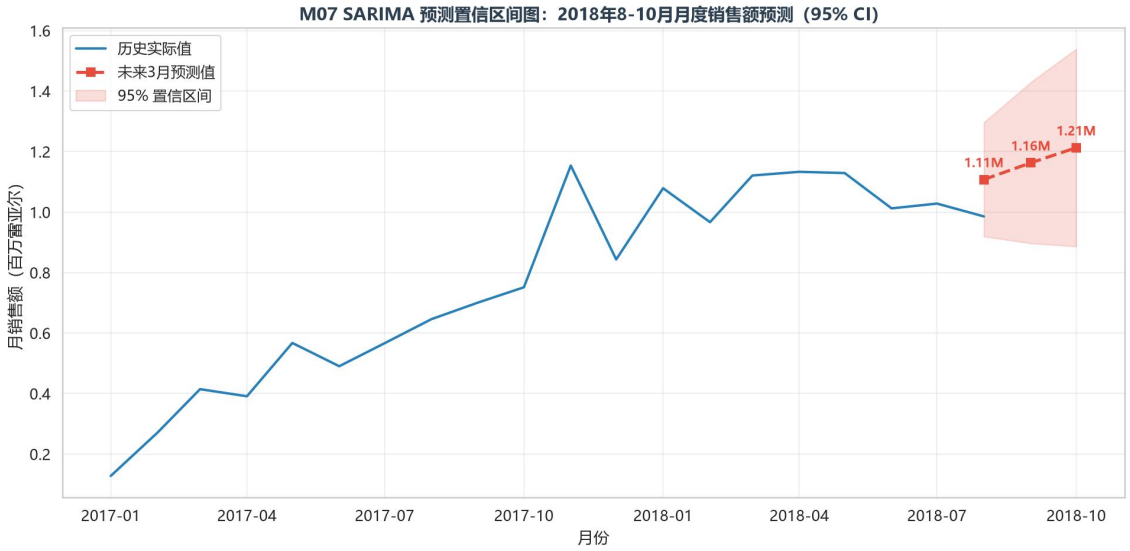


图 5-22 SARIMA 预测 95%置信区间：2018 年 8-10 月（对应 4.3 节）

预测图给出 2018 年 8—10 月的点预测及 95% 置信区间。以 9 月为例，点预测 1,162,670 雷亚尔，区间为 [896,350, 1,428,990]，带宽约 ±23%。随预测步长增加，阴影带逐步张开，符合时序预测不确定性累积的规律。实务上建

议采用“下界备货、上界排班”的双轨策略：按下界锁定采购与库存资金，按上界预留临时人力与运力，从而在控制缺货风险的同时避免过度备货。

5.4 交互式可视化大屏

基于 Pyecharts 2.1.0 构建交互大屏（outputs/dashboard.html），全流程 Python 实现，未使用 Power BI/Tableau。大屏含 10 个页签：使用说明引导页、驾驶舱总览（Grid 四图同屏：月度趋势/州 Top5/支付占比/评分分布）、KPI 指标卡、各州销售额、类别销售额、支付方式、月度趋势、评分分布、配送时长、延迟评分散点。联动机制：①年份 Timeline 一级联动（预聚合 4 套数据，切换零延迟）；②州柱状图 JS click 二级联动（事件总线）；③Tooltip/DataZoom/VisualMap 三级交互。

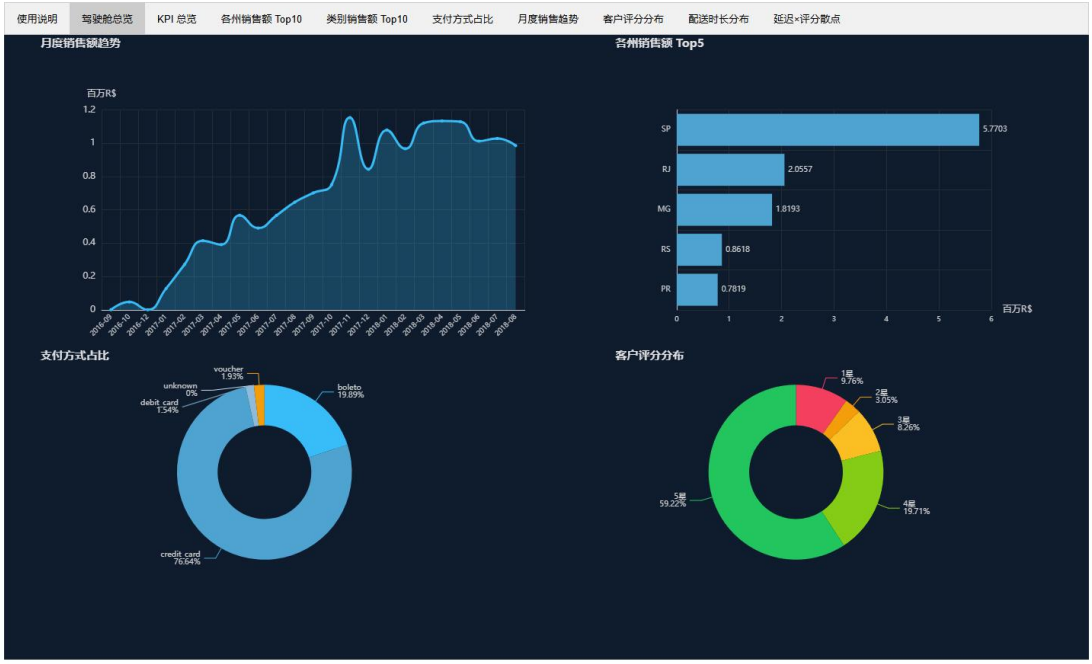


图 5-23 交互大屏：驾驶舱总览页（Grid 四图同屏）

驾驶舱总览采用 Grid 四图同屏版式，一屏回答四个管理层最关心的问题：左上折线看“卖得怎么样”（月度销售额趋势），右上条形看“卖到哪里”（各州 Top5），左下环形看“怎么付的”（支付方式占比），右下环形看“客户满意吗”（评分分布）。四图共享统一深色底与同一套色板，避免多图拼接时的视觉割裂。相比逐个页签翻看，总览页把决策者最常调用的四个视角压缩在一次注视之内，是管理晨会场景的默认首页。



图 5-24 交互大屏：KPI 指标卡页

KPI 指标卡以四张大字号数值卡呈现当期经营基线：总订单 96,478 单、总销售额约 1,542 万雷亚尔、准时送达率 93.2%、平均评分 4.1 分。指标卡不做趋势判断，只承担“当期是否越线”的预警职能，因此排版上放大数值、弱化单位与说明文字，并用留白隔离四项指标以避免相互干扰。四张卡同时也是后续各主题页的“锚”，任何单页异常都应能回溯到这四个基数上。



图 5-25 交互大屏：各州销售额 Top10（内嵌年份 Timeline）

各州销售额页以横向柱状图排序展示 Top10，并在图内嵌入“2016 / 2017 / 2018 / 全部”年份时间轴。时间轴采用 Python 端预聚合的 4 套数据集，切换时无需重新查询，实现零延迟响应；点击任一柱条会触发 click 事件并写入全局状态，供其他图表订阅下钻，构成二级联动入口。这种“先总览、再下钻”的交互路径，符合管理者从宏观到局部的认知顺序。



图 5-26 交互大屏：月度销售额趋势（DataZoom 缩放）

月度趋势页在面积折线基础上增加了底部 DataZoom 缩放条，可拖拽选择任意时间窗。全局视图用于判断年度趋势与季节形态，放大后则能观察黑五、圣诞等短周期脉冲的具体幅度；同一张图兼顾两种时间粒度，避免了为不同粒度重复作图。缩放条同时支持鼠标滚轮与拖拽手柄，是 ECharts 中成本最低、收益最高的交互组件之一。

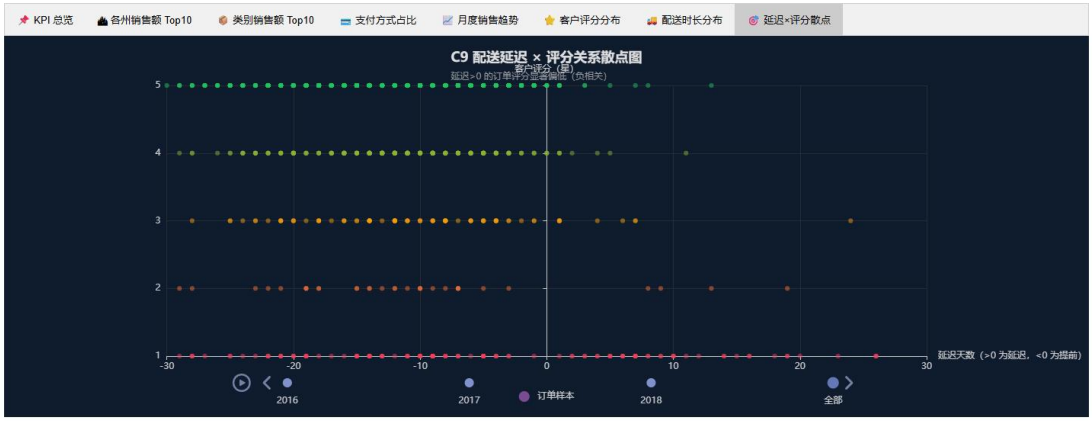


图 5-27 交互大屏：配送延迟×评分散点（VisualMap 映射）

散点图以延迟天数为横轴、评分为纵轴，并用 VisualMap 将评分映射为红—黄—绿色阶。图中呈现清晰的分层：延迟 0 天左侧（提前送达）的点密集分布于 4—5 分绿区；越过 0 天进入延迟侧后，点迅速跌落至橙红区；延迟超过 20 天后几乎不再出现 5 星。这条“断崖”是全文“时效决定满意度”论断最直观的证据，也为延迟预警阈值（建议设在预计送达日前 3 天）提供了设定依据。

5.5 本章小结

本章围绕“把数据讲清楚”这一目标，按“探索—复现—建模—交互”四个层次完成了 27 张图表的绘制：3 张探索性分析图回答“平台现在是什么样”，12 张模板复现图验证“图表类型与数据关系是否匹配”，7 张业务模型图解释“为什么是这样”，5 张大屏截图展示“如何让结论可被交互地使用”。四层之间并非并列，而是一条从描述现象、检验方法、解释机理到支撑决策的递进链条，图表数量与信息密度逐层递增。

在图表规范上，全文统一遵循三条原则：一是“一图一结论”，每张图的标题即其结论的浓缩，读图描述进一步给出数值证据与业务含义，避免出现只有图形没有判断的“装饰性图表”；二是“形式服从数据关系”，时间序列用折线与面积、类别排序用条形、构成关系用饼图与环形图、相关关系用散点、分布形态

用直方图与箱线图、多维比较用气泡图与热力图，同一份数据不因美观而错配图形；三是“视觉一致性”，全部静态图沿用同一主色（#38bdf8）与同一套辅助色，字号、线宽、网格与图例位置保持统一，使 27 张图并置时仍像出自同一套视觉体系。

6 商业案例分析

6.1 案例背景

Olist 平台面临三大痛点：用户复购率低（F 中位数=1）、部分订单物流延迟引发客诉、长尾 SKU 占用仓储资源，亟需数据驱动的精细化运营策略。

6.2 结果解读

数据表明平台价值分布极不均衡：1.5% 的高价值客户是核心利润源；物流时效直接决定客户留存，延迟订单评分断崖式下跌（2.2 vs 4.1）；25% 的 A 类产品是平台"现金牛"，贡献 81.3% 销售额。

6.3 商业建议

（1）高价值客户精准 Retention：对 1,379 名重要价值客户建立 VIP 权益（免运费/优先配送）；对 21,668 名重要挽留客户部署流失预警自动触发召回礼包。

（2）物流延迟治理：延迟率>10% 的路线引入区域仓前置备货；超期未妥投自动推送进度通知+小额补偿；将准时送达率纳入物流商 KPI。

（3）C 类 SKU 优化：连续 3 个月零销量产品下架或按需采购；微销量产品与 A 类捆绑促销。

（4）复购提升：构建首单后 7 天互补品推荐引擎；阶梯会员积分重点触达 22,542 名重要发展客户。

（5）季节性库存：依 SARIMA 预测提前 2 个月规划 A 类安全库存，旺季深度提升 30%。

7 结论与展望

7.1 研究结论

本研究通过 RFM、ABC 与 SARIMA 三大模型，量化了 Olist 平台的用户价值分布与产品贡献结构，证实物流时效对客户满意度的决定性影响，并实现月度销售额的有效预测，为平台精细化运营提供了完整的数据方法论。

综合全文的分析过程与实证结果，可将核心结论归纳为四点：

（1）用户价值高度集中，运营应从“广覆盖”转向“深经营”。1.5% 的重要价值客户贡献约 12% 的销售额，而占客户总数六成以上的低频客群人均消费不足 70 雷亚尔；平台的复购频次中位数为 1，意味着绝大多数交易仍是一次性购买。真正的增长空间不在于继续拉新，而在于把庞大的“重要发展/重要挽留”客群向上迁移一个层级。

（2）商品结构呈典型帕累托分布，长尾是成本而非资产。18 个 A 类品类以 25% 的品类数贡献 81.3% 的销售额，46 个 C 类品类以 63.9% 的品类数仅贡献 9.1%。这意味着库存与流量的配置逻辑应以 A 类保供、B 类观察、C 类瘦身为原则，把有限的仓储与营销资源从长尾中释放出来。

（3）履约时效是满意度的第一解释变量，且影响呈非线性。配送时长与评分的相关系数为 -0.332，延迟订单平均评分仅 2.2 分，而按时或提前送达的订单为 4.3 分；延迟超过 20 天后几乎不再出现 5 星评价。更关键的是，6.8% 的延迟订单平均超期 10.6 天并形成长尾，说明治理重点应是尾部异常而非平均时效。

（4）销售规模可被有效预测，但预测的价值在于区间而非点位。SARIMA(0,1,0)×(0,1,1,12) 在 3 个月回测中取得 21.67% 的 MAPE，能够刻画年度双峰的季节形态；受限于 19 个月的样本长度，模型在峰值月存在低估，因此更适合以“下界备货、上界排班”的方式进入决策流程，而非直接作为财务预算依据。

上述四点结论共同指向一个判断：Olist 下一阶段的增长主要来自存量经营效率而非流量规模。把用户分层做细、把品类结构做轻、把履约尾部做短、把季节节奏做准，四者构成一套相互支撑的精细化运营闭环——用户分层决定资源投向，品类结构决定成本底盘，履约时效决定口碑留存，季节预测决定资金与运力的节奏。这也正是本研究试图提供的、可迁移到其他新兴市场电商平台的分析范式。

7.2 局限性与展望

局限：SARIMA 训练数据仅 19 个月，季节效应估计不充分导致 MAPE 偏高（21.67%）。展望：未来可引入 XGBoost 等机器学习模型融合宏观经济、促销

日历等外部特征提升精度，并结合 NLP 对评论文本做情感分析。

7.3 AI 使用披露

本项目使用 AI 编程助手（Claude Code 和 WorkBuddy）辅助生成 Python 代码框架、优化 Pandas 多表连接逻辑及 Pyecharts 大屏的 Timeline 联动布局代码。核心业务逻辑（RFM 阈值设定、ABC 分类依据、SARIMA 选型）、模型参数解释与商业结论均由本人独立思考完成，AI 仅作为编码效率工具，未替代分析判断。

附录

A 核心代码片段

1. RFM 用户价值分群模型

```
# 计算 R(最近一次消费间隔), F(消费频次), M(消费金额)
rfm = df_master.groupby('customer_id').agg({
    'order_purchase_timestamp': lambda x: (snapshot_date - x.max()).days,
    'order_id': 'count',
    'total_payment_value': 'sum'
}).rename(columns={'order_purchase_timestamp': 'Recency',
                   'order_id': 'Frequency',
                   'total_payment_value': 'Monetary'})

# 以中位数为阈值进行二值化打分
r_score = (rfm['Recency'] <= rfm['Recency'].median()).astype(int)
f_score = (rfm['Frequency'] > rfm['Frequency'].median()).astype(int)
m_score = (rfm['Monetary'] > rfm['Monetary'].median()).astype(int)

# 组合标签并映射为 8 类用户群
rfm['RFM_Score'] = r_score * 100 + f_score * 10 + m_score
# ... (后续映射逻辑：如 111 -> 重要价值客户)
```

2. 帕累托 ABC 产品分类模型

```
# 按产品类别汇总销售额并降序排列
cat_sales = df_master.groupby('product_category_name_english')['total_payment_value'].sum()
cat_sales = cat_sales.sort_values(ascending=False)
total_sales = cat_sales.sum()

# 计算累计占比并分类
cumulative_pct = cat_sales.cumsum() / total_sales
def classify_abc(pct):
    if pct <= 0.80: return 'A'
    elif pct <= 0.90: return 'B'
    else: return 'C'
```

```
cat_sales['Class'] = cumulative_pct.apply(classify_abc)
```

3. SARIMA 时间序列预测与回测

```
from statsmodels.tsa.statespace.sarimax import SARIMAX

# 构建 SARIMA(0,1,0)x(0,1,1,12) 模型
model = SARIMAX(monthly_sales, order=(0, 1, 0), seasonal_order=(0, 1, 1, 12))
results = model.fit()

# 未来 3 个月预测及 95%置信区间
forecast = results.get_forecast(steps=3)
pred_mean = forecast.predicted_mean
conf_int = forecast.conf_int(alpha=0.05)
```

B Gitee/github 仓库链接与目录结构

仓库链接：

仓库公开链接：https://github.com/luoxi-13/Business-data-analysis

(注：期末大作业完整项目代码、数据与文档均存放于该仓库的 Olist_Business_Analysis 文件夹下，核心分析入口为 Olist_Business_Analysis.ipynb)

目录结构：

```
Olist_Business_Analysis/                  # 项目根目录
├── Olist_Business_Analysis.ipynb         # 核心分析笔记本（含代码、图表与业务解读）
├── run_all.py                            # 一键复现入口脚本（由 Notebook 导出）
├── requirements.txt                      # Python 依赖库列表
├── README.md                             # 项目简介、数据来源、复现步骤与图表索引
├── 《商业数据分析》期末大作业.docx        # 最终报告文档
│
├── data/                                 # 数据文件夹
│   ├── raw/                              # 9 张原始 CSV 表
│   └── clean/                            # 清洗后的主表 (olist_master_clean.csv)
│
├── outputs/                              # 输出结果文件夹
│   ├── figures/                          # 自动生成的分析图表
│   │   ├── fig01-fig09 (业务模型图)
│   │   └── template/T01-T12 (12 种可视化模板复现)
│   └── tables/                           # RFM/ABC 结果表 (CSV)
│
├── scripts/                              # 辅助脚本与静态资源
│   ├── run_all.py                        # 一键复现入口
│   └── echarts.min.js                    # 大屏所需的 ECharts 库文件
│
└── docs/                                 # 文档说明
```

C 图表索引（fig01－fig24+ 大屏截图）

1. 业务模型图

编号	图表名称	对应模型/章节
fig04	RFM 用户分群气泡散点图	4.3 RFM 模型
fig07	RFM 八类用户占比环形图	4.3 RFM 模型
fig05	帕累托 ABC 分类双轴图	4.3 ABC 分类
fig08	SARIMA 季节分解趋势图	4.3 SARIMA 预测
fig09	SARIMA 回测误差对比图	4.3 SARIMA 预测
fig06	SARIMA 未来预测与置信区间图	4.3 SARIMA 预测

2. 可视化模板复现

编号	图表类型	图表主题
T01	折线图	每月订单量趋势
T02	面积图	累计月销售额走势
T03	柱形图	各州订单量 Top 15
T04	条形图	产品类别销售额 Top 10
T05	饼图	订单支付方式构成
T06	环形图	客户评分分布
T07	散点图	运费占比 vs 评分相关性
T08	气泡图	各州订单量-客单价-销售额
T09	直方图	订单配送时长分布
T10	箱线图	不同评分下的配送时长分布
T11	热力图	核心指标相关系数矩阵
T12	组合图(双轴)	月销售额(柱) × 平均评分(线)

3. 交互式大屏

大屏截图：见 outputs/figures/dashboard_screenshot

功能说明：基于 Streamlit 搭建，包含 4 个 KPI 指标卡、州销售柱状图、类别条形图、RFM 饼图、月趋势折线图共 6 个联动组件，支持年份/类别/州三维筛选。